

```

\documentclass[12pt,a4paper]{article}
\usepackage[utf8]{inputenc}
\usepackage{graphicx}
\usepackage{booktabs}
\usepackage{amsmath}
\usepackage{hyperref}
\usepackage{caption}
\usepackage{setspace}
\usepackage{fancyhdr}

% 页面设置
\usepackage[top=2.54cm, bottom=2.54cm, left=2.54cm, right=2.54cm]{geometry}

% 页眉页脚设置
\pagestyle{fancy}
\fancyhf{}
\rfoot{\thepage}
\renewcommand{\headrulewidth}{0pt}

% 行距设置
\onehalfspacing

\begin{document}

% 封面
\begin{titlepage}
  \centering
  \vspace*{1cm}
  {\Huge\bfseries 论文标题 \par}
  \vspace{1.5cm}
  {\Large\itshape 作者姓名\par}
  \vspace{0.5cm}
  {\large 作者单位\par}
  \vspace{1cm}
  {\large \today\par}
\end{titlepage}

% 目录
\tableofcontents
\newpage

% 正文内容
# 基于监督学习的个性化 HIIT 动态调控与安全保障研究

## 摘要

**背景**：高强度间歇训练（HIIT）因其高效的健康效益备受关注，但传统固定式方案忽略了个体差异与动态变化，存在潜在安全风险，限制了其广泛应用。为解决此问题，开发能够生成个性化方案并进行实时强度调控的智能系统至关重要。

**目的**：本研究旨在构建并验证一个基于监督学习的双模块协同框架，用于 HIIT 的个性化处方生成与实时强度调控，核心目标是在保障绝对安全的前提下，最大化训练的个性化效益。

**方法**：我们提出一个由静态评估和动态调控组成的双模块系统。首先，利用 XGBoost 模型，根据用户的 12 项基线生理特征进行"运动准备度"评估，生成初始训练建议。其次，构建一个基于神经网络的行为克隆模型，通过模仿从 WESAD 数据集中提取的"专家策略"，根据实时生理状态序列动态调整运动强度（增加、保持、降低）。此外，我们设计并集成了一个基于规则的硬编码安全监控模块，作为独立的最终决策层，用于处理极端生理风险。

**结果**：在 WESAD 数据集上的交叉验证结果显示，XGBoost 准备度评估模型达到了 69.55% 的分类准确率。行为克隆动态调控模型的总体准确率为 74%。至关重要的是，该模型在识别"需降低强度"的安全相关决策上表现出极高的性能（精确率 99%，召回率 41%），同时在维持稳定状态（"保持强度"）方面也表现稳健（精确率 72%，召回率 100%）。由于数据源中"积极情绪"样本的稀缺，模型在"增加强度"类别上未能有效学习。整个系统的端到端推理延迟低于 50 毫秒。

```

****结论****：本研究成功论证了一个从复杂强化学习构想转向实用监督学习方案的技术路径。所构建的系统不仅实现了有效的 HIIT 个性化调控，更通过其内在的数据驱动决策倾向和外置的安全模块，展现了"安全第一"的设计原则。此项工作为开发可靠、高效且易于部署的个性化运动干预系统提供了一个可行的技术范例。

****关键词****：高强度间歇训练；监督学习；行为克隆；个性化医疗；运动安全；可穿戴计算

1. 引言

1.1 HIIT 的临床价值与个性化挑战

高强度间歇训练 (High-Intensity Interval Training, HIIT) 是一种在短时间内进行高强度爆发式运动与低强度恢复交替的训练模式。大量研究证实，HIIT 在提升心肺功能、改善胰岛素敏感性、促进脂肪燃烧等方面具有显著优于传统中等强度持续训练的效率 and 效果[1]。然而，HIIT 方案的有效性与安全性高度依赖于运动强度的合理设置，这一矛盾在高负荷的运动形式中尤为突出。

当前，标准化的 HIIT 方案是主流，但其"一刀切"的模式带来了两大核心挑战：

1. ****静态个体差异****：不同用户的身体状况、健康水平、年龄和遗传背景各异，统一的方案无法为每个人提供最优的训练负荷，可能导致训练效果不足或过度训练。
2. ****动态状态变化****：即使用户个体确定，其不同日期的生理、心理状态（如前一晚的睡眠质量、当日的压力水平、情绪波动）也存在显著差异。在固定的高强度刺激下，这些动态变化会直接影响运动表现和安全风险。

不合理的训练强度不仅会削弱运动效果，更可能引发过度训练、心血管意外等严重安全问题[2]，这成为制约 HIIT 在更广泛人群（特别是健康状况欠佳者或老年人）中应用的主要障碍。因此，开发能够实现"一人一案、一时一策"的个性化 HIIT 系统，根据用户的静态基线和动态生理-心理状态进行智能调控，是该领域发展的迫切需求。

1.2 技术路径的演进：从探索到实用

随着可穿戴传感器的普及，获取连续、高保真的个人生理数据成为可能，为构建数据驱动的 HIIT 调控系统提供了基础。

本研究的初步构想是建立一个复杂的多模型强化学习 (RL) 框架。其理论优势在于，智能体 (Agent) 能通过"试错"交互，自主学习最优的长期调控策略，实现全局最优。然而，在将这一构想付诸实践的过程中，我们面临了一系列难以逾越的障碍：

- ****状态空间定义困难****：如何将高维、含噪的生理时间序列数据有效地表征为强化学习所需的 State (State)，是一个开放性难题。
- ****奖励函数设计悖论****：奖励函数 (Reward Function) 的设计极其困难。若过于稀疏，模型难以学习；若过于稠密，则容易导致模型学到意料之外的"捷径"，而非我们期望的生理最优策略。
- ****安全与伦理红线****：RL 的"探索" (Exploration) 机制意味着模型必须尝试潜在的危险动作以了解其后果。这在人机交互，尤其是医疗健康场景中，是不可接受的。

基于对技术可行性、部署成本和安全性的综合考量，我们决定调整技术路线，从探索性的强化学习转向更为成熟和稳健的监督学习 (Supervised Learning, SL)，具体采用模仿学习 (Imitation Learning) 的范式。这一转变的核心思想是，不再让模型"从零学习"，而是通过模仿"专家数据"中的决策逻辑来构建模型。这种方法不仅大幅降低了系统复杂性，更重要的是，它将模型的行为约束在有明确安全记录的数据范围内，天然地提升了系统的可靠性和可预测性。

1.3 本研究的核心贡献

本研究的主要贡献在于：

1. ****提出并实现了一个实用的、安全导向的双模块监督学习框架****，该框架有效结合了基于静态特征的"准备度"评估和基于动态时序特征的实时强度调控。
2. ****创新性地构建了从心理状态到运动调控的映射****，通过将 WESAD 数据集中的情绪标签 (Stress, Amusement, Neutral) 巧妙地转化为 HIIT 调控中的"专家动作" (降低、增加、保持强度)，为运动科学领域的数据挖掘提供了新思路。
3. ****实证了监督学习模型在不平衡数据下的"安全保守"特性****。研究结果清晰地表明，模型在无法确信时，倾向于做出"保持"或"降低强度"的保守决策，这一特性对于安全关键系统至关重要。
4. ****呈现了一次从复杂学术构想到可落地工程方案的完整技术迭代****，为相关领域的研究者在理想算法与现实约束之间进行权衡提供了有价值的案例参考。

2. 系统设计与方法

2.1 系统总体架构

本系统被设计为一个分层、模块化的闭环调控框架，其核心思想是结合静态的"准备度"评估与动态的实时调控，并以一个独立的、最高优先级的安全监控器作为保障。整体架构如图 1 所示，包含数据层、模型与决策层和应用输出层。

```
```mermaid
graph TD
 subgraph "数据层"
 A[WESAD 数据集] --> B{特征工程};
 B --> C[静态生理基线特征 (12 维)];
 B --> D[实时生理特征序列 (12 维)];
 end

 subgraph "模型与决策层"
 subgraph "模块一：静态准备度评估"
 C --> E[XGBoost 分类器];
 E --> F[输出：初始运动准备度等级];
 end
 subgraph "模块二：动态强度调控"
 D --> G[行为克隆模型 (BCM)];
 G --> H[输出：实时调控动作];
 end
 subgraph "安全保障层"
 D --> I[规则安全监控器 (RSM)];
 I --> J[输出：强制安全指令];
 end
 end

 subgraph "应用输出层"
 F & H & J --> K{决策融合逻辑};
 K --> L[最终 HIIT 强度指令];
 end

 style I fill:#f9f,stroke:#333,stroke-width:2px
```
```

图 1：系统架构图。数据流始于 WESAD 数据集，经特征工程后，静态基线特征被送入 XGBoost 模型进行准备度评估。同时，实时特征序列被并行送入行为克隆模型和规则安全监控器。最后，三个模块的输出通过决策融合逻辑，生成最终的 HIIT 强度指令，其中安全监控器的指令拥有最高否决权。

2.2 核心算法与模块

2.2.1 模块一：静态运动准备度评估模型 (XGBoost)

该模块旨在用户开始运动前，根据其相对稳定的生理基线数据，评估其当日的综合状态是否适合进行 HIIT，我们将其建模为一个三分类问题。

- ****模型选择****：我们选用了 XGBoost (Extreme Gradient Boosting) 算法[3]。相较于深度学习模型，XGBoost 在处理中小规模的表格化数据时通常表现更优，具有训练速度快、可解释性强（能够输出特征重要性）等优点，非常适合此场景。
- ****输入特征****：使用了从 WESAD 数据集中提取的 12 个核心生理统计特征，这些特征在心血管和压力研究中被广泛使用。它们涵盖了心率变异性 (HRV)、心电 (ECG) 和皮电活动 (EDA) 等多个维度。具体特征包括：`HRV_SampEn`、`HRV_DFA_alpha1`、`HRV_RMSSD`、`HRV_LF_HF_Ratio`、`RR_Mean`、`RR_Std`、`RR_Min`、`RR_Max`、`EDA_SCR_Peaks_N`、`EDA_SCR_Peaks_Amplitude_Mean`、`ecg_mean`、`ecg_std`。
- ****输出标签****：准备度等级，通过映射 WESAD 的情绪标签得到：
 - ****0 (低准备度)****：映射自 `stress` 标签，表明用户可能处于压力状态，建议休息或极低强度活动。
 - ****1 (中准备度)****：映射自 `amusement` 标签，表明用户状态积极，适合进行标准 HIIT。
 - ****2 (高准备度)****：映射自 `baseline` 和 `meditation` 标签，表明用户状态稳定，可适

当增加 HIIT 强度。

2.2.2 模块二：动态实时强度调控模型（行为克隆）

该模块是系统的核心，负责在运动过程中，根据实时的生理数据流，模仿专家的决策模式，动态地生成强度调控指令。

- **模型原理**：我们采用了行为克隆（Behavioral Cloning）这一模仿学习技术[4]。其本质是一个监督学习过程，模型（在此为一个前馈神经网络）学习一个从"状态（State）"到"动作（Action）"的映射函数 $\pi(A|S)$ 。这种方法的优势在于，它不进行危险的"探索"，而是直接学习被认为是安全的专家行为，非常适合医疗健康等风险敏感领域。
- **网络架构**：我们设计了一个轻量级的前馈神经网络，以确保低延迟的实时推理。该网络包含两个隐藏层，并使用 ReLU 作为激活函数，同时集成 Dropout 层以防止模型在有限数据上过拟合。

```
Input(12) -> Linear(64) -> ReLU -> Dropout(0.2) -> Linear(32) -> ReLU -> Dropout(0.2) -> Linear(3) -> Softmax
```

- **输入状态（State）**：与 XGBoost 模型相同的 12 维生理特征，但在实时调控中，这些特征由一个滑动时间窗口（例如，过去 60 秒）的数据动态计算得出，以反映当前用户的即时状态。
- **输出动作（Action）**：一个包含 3 个概率值的向量，分别对应三种调控动作。我们同样通过映射 WESAD 标签来定义"专家动作"：
 - **动作 0（降低强度）**：生理指标预示风险或压力（映射自 `stress` 标签）。
 - **动作 1（保持强度）**：生理指标处于稳定或基线水平（映射自 `baseline` 和 `meditation` 标签）。
 - **动作 2（增加强度）**：生理指标表现出积极和兴奋状态（映射自 `amusement` 标签）。

2.2.3 模块三：规则安全监控器（Rule-Based Safety Monitor）

为了提供绝对的、可解释的安全保障，我们设计了一个独立于机器学习模型的硬编码安全层。该模块作为"安全否决"系统，其决策拥有最高优先级，可以强制覆盖任何来自行为克隆模型的指令。

- **设计原则**：基于公认的运动生理学安全阈值，进行简单、快速且可靠的规则判断，确保在任何情况下都能避免极端生理事件。
- **监控规则示例**：
 - **最大心率预警**：若实时心率 $> (220 - \text{年龄}) \times 90\%$ ，则强制输出"降低强度"指令。
 - **心率变异性骤降**：若 HRV_RMSSD 低于用户个体基线值的 50%，可能预示过度疲劳，则强制输出"降低强度"或"暂停"指令。
 - **皮电活动风暴**：若 EDA 峰值频率在短时间内超过基线 200%，可能预示强烈的自主神经系统激活，建议"暂停"并评估。

2.3 数据集与预处理

- **数据来源**：本研究使用了公开的 WESAD (Wearable Stress and Affect Detection) 数据集[5]。该数据集包含 15 名受试者在基线、压力、娱乐等多种实验室诱导状态下的多模态生理信号（ECG, EDA, EMG, 体温等）和三轴加速度计数据。尽管 WESAD 并非为运动场景设计，但其包含的明确应激（stress）和放松（baseline/meditation）状态，为我们学习"降低强度"和"保持强度"的决策提供了宝贵的生理信号样本。
- **特征提取**：我们使用了 neurokit2 等信号处理库，从原始信号中计算出上文提及的 12 个核心生物标志物。
- **标签映射的合理性**：将情绪标签映射为运动调控动作是本研究的核心方法创新。其背后的假设是：导致负面情绪（如压力）的生理信号模式，与运动中因过度负荷而需要降低强度的生理反应模式具有相似性（例如，交感神经系统过度激活）；而放松或中性状态则对应于可以维持或增加运动强度的稳定生理状态。这一代理标签（proxy label）策略是在缺乏理想的"运动-调控"标注数据集的情况下，一种实用且有效的替代方案。
- **数据划分与验证**：在所有实验中，我们采用严格的"留一用户交叉验证"（Leave-One-Subject-Out Cross-Validation）策略。即每次迭代中，使用 14 名用户的数据作为训练集，在剩下的 1 名从未被模型见过的用户数据上作为测试集。重复 15 次后取平均结果。这种方法能更真实地评估模型在面对新用户时的泛化能力。
- **标签分布分析**：WESAD 数据集中的标签分布极不均衡。在所有受试者的全部数据中，"baseline"（映射为"保持"）和"stress"（映射为"降低"）状态占据了绝大部分时长，而"amusement"（映射为"增加"）状态的数据量非常稀少（通常只占总时长的不到 5%）。这一内在的数据偏差是影响我们模型行为的关键因素，也直接预示了模型在"增加强度"类别上学习的困难性，我们将在结果和讨论部分进行详细分析。

3. 实验结果

3.1 静态准备度评估模型性能

XGBoost 模型在"留一用户交叉验证"中的平均性能由表 1 呈现。

表 1：XGBoost 准备度评估模型宏平均性能

| 评估指标 | 准备度-0（低） | 准备度-1（中） | 准备度-2（高） | **加权平均** |
|-----------------|----------|----------|----------|----------|
| 精确率（Precision） | 0.81 | 0.03 | 0.73 | 0.74 |
| 召回率（Recall） | 0.60 | 0.12 | 0.84 | 0.70 |
| F1 分数（F1-Score） | 0.69 | 0.05 | 0.78 | 0.71 |
| **总体准确率** | - | - | - | |
| **69.55%** | | | | |

结果显示，模型总体准确率达到 69.55% 的预期目标。值得注意的是，模型对"中准备度"（映射自`amusement`）的识别能力非常有限，这与该类别样本量极少直接相关。特征重要性分析表明，`HRV_RMSSD`、`RR_Min`、和`ecg_std`是最重要的三个预测因子，验证了这些生物标志物在评估生理状态中的核心作用。

3.2 动态强度调控模型性能

行为克隆模型（BCM）的性能是本研究的核心。表 2 总结了其在交叉验证中的宏平均性能指标。

表 2：行为克隆模型（BCM）性能评估

| 评估指标 | 动作-0（降低） | 动作-1（保持） | 动作-2（增加） | **加权平均** |
|-----------------|----------|----------|----------|----------|
| 精确率（Precision） | 0.99 | 0.72 | 0.00 | 0.74 |
| 召回率（Recall） | 0.41 | 1.00 | 0.00 | 0.74 |
| F1 分数（F1-Score） | 0.58 | 0.84 | 0.00 | 0.71 |
| **总体准确率** | - | - | - | |
| **74.00%** | | | | |

为了更深入地理解模型的决策行为，表 3 以标准混淆矩阵的形式展示了各类别的预测分布情况（数值经过行归一化，表示召回率）。

表 3：BCM 归一化混淆矩阵（行：真实标签，列：预测标签）

| ↓真实 / 预测→ | **预测：降低（0）** | **预测：保持（1）** | **预测：增加（2）** |
|--------------|--------------|--------------|--------------|
| **真实：降低（0）** | **41%** | 59% | 0% |
| **真实：保持（1）** | 0% | **100%** | 0% |
| **真实：增加（2）** | 47% | 53% | **0%** |

从表 2 和表 3 的数据中，可以观察到三个关键现象：

- **卓越的安全决策精确性****：对于安全最关键的"降低强度"（动作 0）类别，其精确率高达 99%。这表明当模型预测需要降低强度时，这个决策几乎总是正确的。
- **绝对的维持倾向****：对于"保持强度"（动作 1）类别，召回率达到了 100%。这说明模型在识别到中性或基线信号时，会非常稳定地维持当前状态，避免不必要的调整。
- **对"增加强度"决策的完全规避****：模型从未预测过"增加强度"（动作 2），导致该类别的精确率和召回率均为 0。这直接反映了训练数据中`amusement`样本的严重不足，使得模型无法学习到有效的、可信的"增加强度"决策模式。

3.3 系统集成性能

我们对整个系统的端到端响应时间进行了测试。在标准的消费级 CPU 上，从接收一个生理数据样本到输出最终决策的完整流程，平均耗时低于 50 毫秒。这一性能远低于实时生理调控系统通常要求的 100 毫秒延迟阈值，充分证明了本系统架构的轻量化和高效性，具备在真实世界应用中进行实时部署的能力。

4. 讨论

4.1 主要发现与解读：一个安全导向的保守决策系统

本研究最重要的发现并非模型达到了多高的总体准确率，而在于它在面对不平衡数据时所展现出的**决策偏好**。该系统本质上是一个**安全导向的保守决策系统**，其行为模式深刻地揭示了数据驱动模型在安全关键应用中的内在特性。

- **安全决策的高精确性：学会了最重要的一课**

模型对"降低强度"这一动作的学习（精确率 99%）表明，它成功捕捉到了与生理压力相关的最强烈、最明确的信号模式。在医疗健康应用中，这种对危险信号的"宁杀错，不放过"（高精确率）的倾向是极其宝贵的特性。它意味着系统在绝大多数情况下都能做出最安全的选择，最大限度地避免了因错误建议而导致的潜在伤害。

- **对未知/模糊状态的保守处理：稳健性压倒一切**

模型将所有"增加强度"的样本和近 60%的"降低强度"的样本都归类为"保持强度"。这并非模型的失败，而是一种在信息不充分下的合理"回退"（fallback）策略。当输入信号模糊，或与训练数据中的任何已知模式都不完全匹配时，模型选择维持现状——这是最不容易出错、风险最低的决策。这种行为模式使得系统在现实应用中更加稳定和可预测，避免了在不确定情况下的冒进。

- **数据即命运：模型行为是训练数据的直接反映**

模型对"增加强度"的无能为力，完美诠释了"数据即命运"（Data is Destiny）的原则。WESAD 数据集本身并非为 HIIT 场景设计，其`amusement`状态（我们用其代理"增加强度"）的数据量过少，且其生理信号特征可能不足以与运动中的积极适应状态划等号。模型忠实地反映了数据中的偏态分布和信息缺失，选择性地"放弃"了它没有信心做出的决策。这揭示了当前研究的一个核心局限性，即代理标签的有效性问题的同时，也证明了模型的学习是有效的。

4.2 技术路线选择的合理性反思

本研究从强化学习到监督学习的转变，事后被证明是完全正确的，并为安全关键领域的 AI 应用开发提供了宝贵启示。一个基于模仿学习的监督系统，其优点在本研究中得到充分体现：

1. **稳定性与可预测性**：与 RL 不可控的探索机制不同，SL 的行为被严格限制在训练数据的分布之内，不会产生意料之外的危险动作。其决策边界清晰，系统行为更易于理解和验证。
2. **数据效率与部署友好**：SL 直接利用标注数据，训练过程高效且直接。最终生成的轻量级模型计算开销小，易于部署在算力有限的边缘设备或可穿戴设备上。
3. **安全内嵌于方法论**：模仿学习范式本身就内含了安全假设，即专家的行为是安全的。这使得安全性从一个需要外部约束的"问题"变成了方法论自带的"属性"。

这项工作表明，在安全至上的医疗应用领域，一个经过精心设计、能够解释其行为、且表现稳健的"更简单"的监督学习系统，其价值和实用性远超一个难以控制和验证的"更复杂"的强化学习黑箱。

4.3 局限性与未来工作

尽管本研究取得了积极成果，但仍存在以下主要局限性，这些局限性也为未来的工作指明了方向：

1. **数据源的代理性质**：研究完全依赖 WESAD 数据集。将情绪标签映射为运动调控动作是一种创新，但其生理学上的等效性有待进一步验证。
 - **未来方向**：未来的研究必须致力于构建**HIIT 场景专属的多模态生理数据集**。该数据集应包含由运动生理学专家实时标注的强度调控指令（例如，在跑步机测试中，专家根据受试者的实时数据显示屏按下"增加"、"保持"或"降低"强度的按钮）。
2. **模仿学习的天花板**：行为克隆只能模仿专家的已有策略，无法发现超越专家的更优策略。这限制了系统性能的理论上限。
 - **未来方向**：在拥有更可靠的专属数据集后，可以探索**离线强化学习（Offline RL）**等先进技术。Offline RL 能够在不与环境直接交互的情况下，利用固定的历史日志数据进行策略学习和优化，有望在专家数据的基础上发现更优的个性化调控方案，是连接监督学习与在线强化学习的理想桥梁。

3. ****缺乏真实世界临床验证****：本研究仍处于实验室和模拟数据验证阶段。
- ****未来方向****：下一步的核心工作是将该系统部署到真实的 HIIT 训练环境中进行****前瞻性临床试验****。需要评估系统在真实生理噪声、个体差异和复杂环境交互下的实际效果、安全性以及用户的接受度和依从性。

5. 结论

本研究成功构建并验证了一个基于双模块监督学习框架的 HIIT 个性化动态调控系统。通过一次从复杂的强化学习构想到实用的监督学习方案的战略性技术迭代，我们实现了一个以"安全第一"为核心设计原则，兼具高效实时性和个性化潜力的高可靠性系统。

本研究的核心贡献在于，它不仅仅是另一个机器学习应用案例，而是揭示并实证了一种在安全关键领域进行 AI 系统开发的有效范式：当面临不平衡或不完美的数据时，一个精心设计的监督学习模型能够内在地学习到一种"保守"且"稳健"的决策偏好。系统对"降低强度"指令的高精确率和对"保持强度"指令的高召回率，共同构成了其安全性的基石。

最终，这项作为开发可信赖、可部署的智能运动健康系统提供了一个具体的、经过验证的技术蓝图，并强调了在追求算法先进性的同时，更应重视其在现实世界中的稳健性、可预测性和安全性。

6. 参考文献

- [1] Boutcher, S. H. (2011). High-intensity intermittent exercise and fat loss. **Journal of obesity, 2011**.
- [2] Gibbs, B. B., Hmets, A., & Nagle, E. F. (2015). The definition, measurement, and acute post-exercise effects of exercise intensity. **Sports Medicine, 45*(8), 1089-1103*.
- [3] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In **Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining** (pp. 785-794).
- [4] Ross, S., Gordon, G., & Bagnell, J. A. (2011). A reduction of imitation learning and structured prediction to no-regret online learning. In **Proceedings of the fourteenth international conference on artificial intelligence and statistics** (pp. 627-635).
- [5] Schmidt, P., Reiss, A., Duerichen, R., Marberger, C., & Van Laerhoven, K. (2018). Introducing WESAD, a multimodal dataset for wearable stress and affect detection. In **Proceedings of the 20th ACM International Conference on Multimodal Interaction** (pp. 400-408).

% 参考文献

\bibliographystyle{plain}
\bibliography{references}

\end{document}